Практическое занятие 4: СБОР И ПОДГОТОВКА ДАННЫХ

Цели работы:

- ознакомление со структурой источников открытых данных, изучение способов хранения и представления данных;
- приобретение навыка построения системы сбора данных.

Задачи:

1 Автоматизированный сбор данных табло аэропортов с применением MS Excel.
2 Исследование наборов данных, представленных на портале открытых данных data.gov.ru.
3 Исследование наборов данных, представленных на портале data.worldbank.org.

В качестве инструментального средства используется программное обеспечение Microsoft Excel.

Оглавление

Краткие сведения из теории
Сбор данных
Источники данных
Сбор данных
Автоматизированный сбор данных с применением MS Excel
Подготовка данных
Программное обеспечение
Задание 1: Автоматизированный сбор данных табло аэропортов с применением MS Excel
Задание 2: Исследование наборов данных, представленных на портале открытых данных data.gov.ru
Задание 3: Исследование наборов данных, представленных на портале data.worldbank.org

Краткие сведения из теории

Анализ данных – процесс поиска скрытых закономерностей и генерации новых знаний.

Основные задачи анализа данных:

- прогнозирование;
- классификация;
- поиск схожих черт;
- выдача рекомендаций;
- выявление отклонений.

Анализ данных – междисциплинарная область знаний, находящаяся на стыке математики, теории алгоритмов и информационных технологий.

В англоязычных источниках для обозначения сферы анализа данных используется термины Data Mining (интеллектуальный анализ данных) и Machine Learning (машинное обучение).

Необходимость анализа больших объемов накопленных данных привела к созданию специализированных подразделений во многих компаниях. Некоторые компании, например Яндекс, реализуют собственные образовательные проекты в этой области.

Сбор данных

Данные по виду можно подразделить на числовые и категориальные.

Числовые данные (Numerical Data) – это данные, характеризующие состояние какого-либо параметра изучаемого объекта. Наиболее часто такие данные бывают представлены вещественными числами. Примерами числовых данных являются заработная плата, население страны, артериальное давление, температура воздуха.

Категориальные данные (Categorical Data) – это данные, образующие признак принадлежности к какой-либо группе. Примерами категориальных данных являются экзаменационная оценка, цвет автомобиля, уровень образования человека.

В фрагменте набора данных по маркетинговой кампании в банке поля Age и Balance являются числовыми, а поля Job, Marital, Education и Housing – категориальными (табл. 1).

Таблица 1. Анкетные данные клиентов банка

Age	Job	Marital	Education	Balance	Housing
58	management	married	tertiary	2143	yes
44	technician	single	secondary	29	yes
33	entrepreneur	married	secondary	2	yes
47	blue-collar	married	unknown	1506	yes
33	unknown	single	unknown	1	yes
35	management	married	tertiary	231	yes

28	management	single	tertiary	447	yes
42	entrepreneur	divorced	tertiary	2	yes
58	retired	married	primary	121	yes
43	technician	single	secondary	593	yes

Источники данных

В настоящее время в открытом доступе есть большое количество баз данных, содержащих самые разнообразные сведения.

По состоянию на 23 декабря 2015 года самым большим источником открытых данных по Российской Федерации является «Портал открытых данных Российской Федерации» (https://data.gov.ru), содержащий более 4,1 тыс. наборов данных. Предполагается, что предоставление свободного доступа к отдельным данным может способствовать повышению качества государственного, регионального и муниципального управления. Принцип открытости получил отдельное название – «открытые данные» (Open Data). В Российской Федерации концепция открытых данных упоминается в Федеральном законе «Об информации, информационных технологиях и о защите информации».

Также большой объем открытых статистических данных содержится в банке данных Федеральной службы государственной статистики (https://www.gks.ru).

Сбор данных

Сбор данных – процесс формирования структурированного набора данных в цифровой форме. В некоторых случаях процесс сбора данных может включать также этап оцифровки.

Как правило, оцифрованные данные бывают представлены в виде:

- электронных таблиц в форматах XLS либо ODS;
- текстовых файлов в формате CSV;
- веб-страниц в формате HTML;
- файлов в формате XML;
- базы данных с доступом по технологии JSON либо через специализированный интерфейс (API).

Автоматизированный сбор данных с применением MS Excel

В случаях, когда источники данных структурированы и представлены в сети Интернет, возможна реализация автоматизированного сбора данных. Программное обеспечение Microsoft Excel имеет специальное средство для сбора данных, в том числе из сети Интернет.

Пример реализации автоматизированного сбора данных на примере онлайн-табло аэропорта Шереметьево: для получения данных необходимо выполнить следующие шаги:

1) Запустить программу Microsoft Excel.
2) Перейти пункт главного меню «Данные».
3) Выбрать пункт «Из интернета» и в диалоговом окне создания запроса внести адрес https://rasp.yandex.ru/station/9600213/ (рис. 1) и нажать кнопку ПУСК.
4) На открывшейся странице с помощью зеленого маркера выделить таблицу, содержащую искомые данные (рис. 2). Результат представлен на рис. 3.
5) Щёлкнуть ЛКМ по кнопке ИМПОРТ (рис. 2).

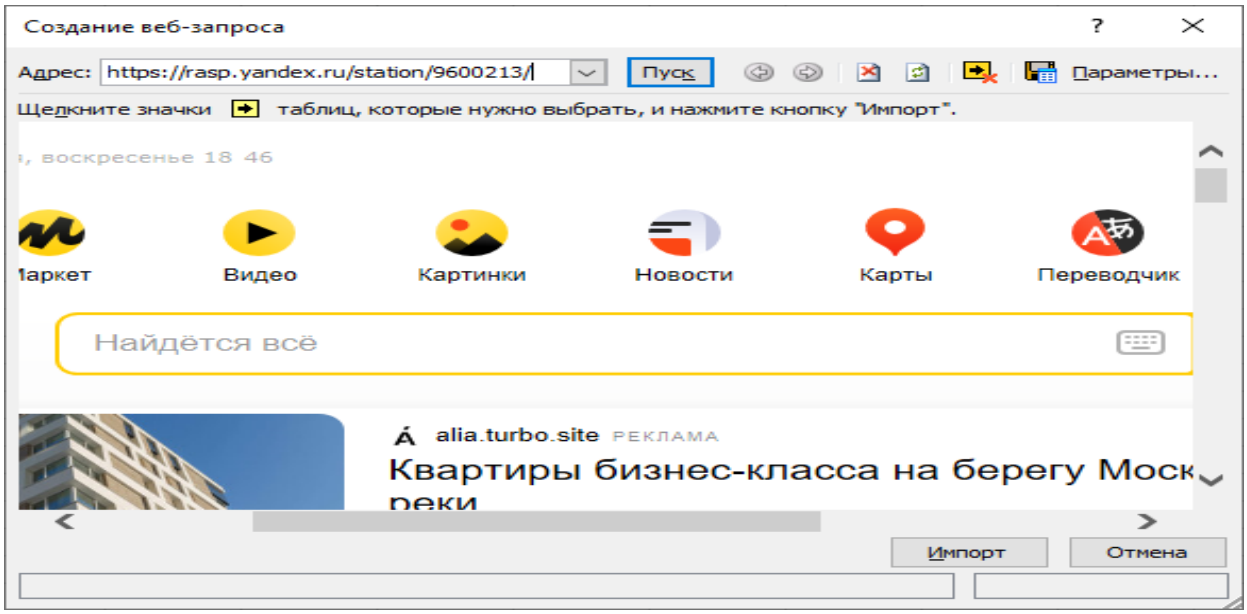

Рисунок 1 – Создание запроса

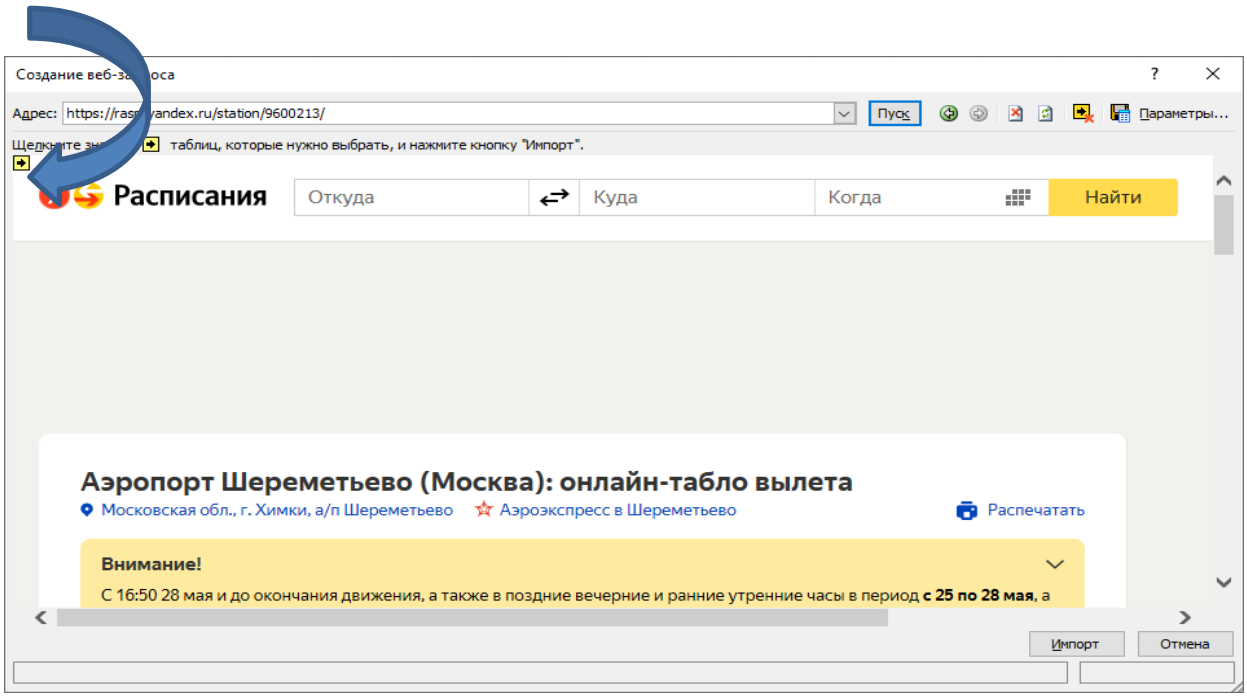

Рисунок 2 – Выделение таблицы с данными

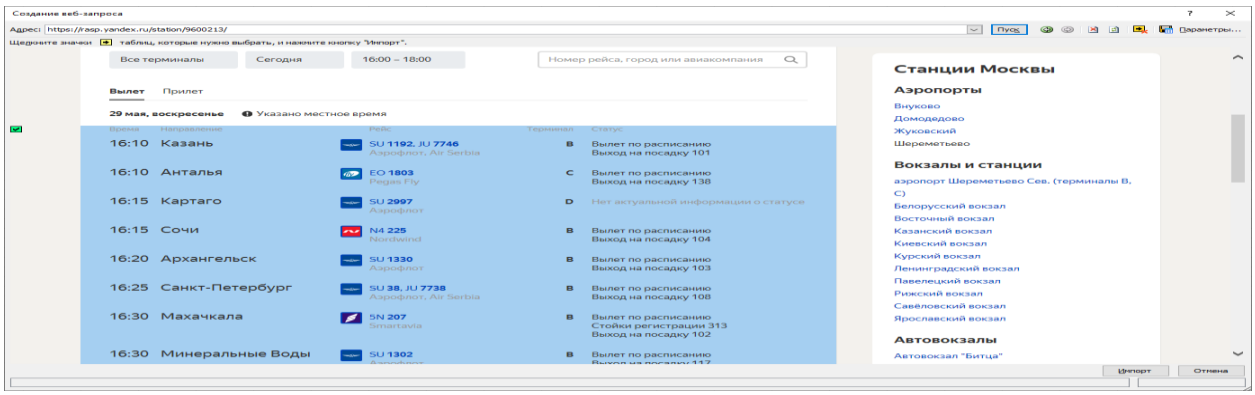

Рисунок 3 – Результат выделения таблицы с данными

В результате выполненных действий искомые данные будут импортированы на активный лист документа Excel (рис. 4).

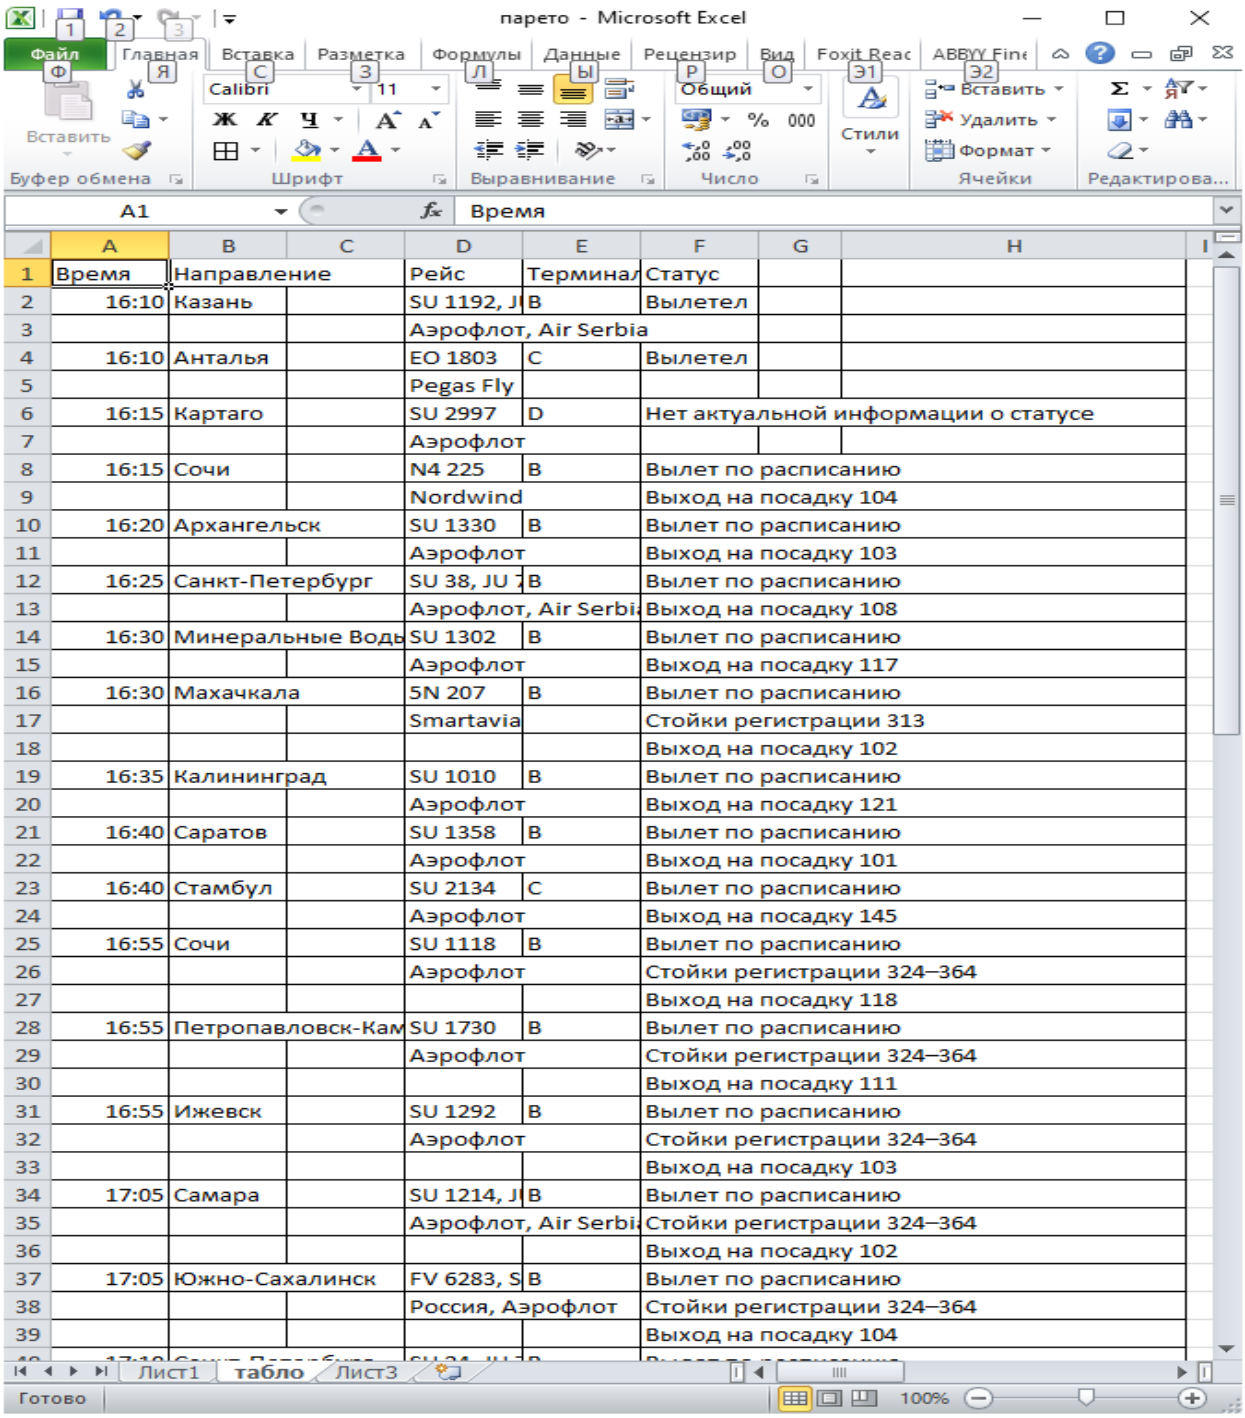

	A	B	C	D	E	F	G	H
1	Время	Направление		Рейс	Терминал	Статус		
2	16:10	Казань		SU 1192, J	B	Вылетел		
3				Аэрофлот, Air Serbia				
4	16:10	Анталья		EO 1803	C	Вылетел		
5				Pegas Fly				
6	16:15	Картаго		SU 2997	D	Нет актуальной информации о статусе		
7				Аэрофлот				
8	16:15	Сочи		N4 225	B	Вылет по расписанию		
9				Nordwind		Выход на посадку 104		
10	16:20	Архангельск		SU 1330	B	Вылет по расписанию		
11				Аэрофлот		Выход на посадку 103		
12	16:25	Санкт-Петербург		SU 38, JU 7	B	Вылет по расписанию		
13				Аэрофлот, Air Serbi		Выход на посадку 108		
14	16:30	Минеральные Воды		SU 1302	B	Вылет по расписанию		
15				Аэрофлот		Выход на посадку 117		
16	16:30	Махачкала		5N 207	B	Вылет по расписанию		
17				Smartavia		Стойки регистрации 313		
18						Выход на посадку 102		
19	16:35	Калининград		SU 1010	B	Вылет по расписанию		
20				Аэрофлот		Выход на посадку 121		
21	16:40	Саратов		SU 1358	B	Вылет по расписанию		
22				Аэрофлот		Выход на посадку 101		
23	16:40	Стамбул		SU 2134	C	Вылет по расписанию		
24				Аэрофлот		Выход на посадку 145		
25	16:55	Сочи		SU 1118	B	Вылет по расписанию		
26				Аэрофлот		Стойки регистрации 324–364		
27						Выход на посадку 118		
28	16:55	Петропавловск-Кам		SU 1730	B	Вылет по расписанию		
29				Аэрофлот		Стойки регистрации 324–364		
30						Выход на посадку 111		
31	16:55	Ижевск		SU 1292	B	Вылет по расписанию		
32				Аэрофлот		Стойки регистрации 324–364		
33						Выход на посадку 103		
34	17:05	Самара		SU 1214, J	B	Вылет по расписанию		
35				Аэрофлот, Air Serbi		Стойки регистрации 324–364		
36						Выход на посадку 102		
37	17:05	Южно-Сахалинск		FV 6283, S	B	Вылет по расписанию		
38				Россия, Аэрофлот		Стойки регистрации 324–364		
39						Выход на посадку 104		

Рисунок 4 – Импортированные данные в MS Excel

Подготовка данных

Для использования в системах анализа данные должны быть представлены в определенном, как правило, табличном виде. Однако зачастую наборы данных имеют следующие особенности:

- отличную от табличной форму представления;
- пропуски отдельных данных;
- некорректные значения;
- большие числовые значения;
- текстовые данные.

Перечисленные особенности могут либо привести к затруднениям в процессе дальнейшей обработки данных, либо сделать её невозможной. Для устранения отмеченных несоответствий могут быть применены следующие операции:

- **структурирование** – приведение данных к табличному (матричному) виду;
- **отбор** – исключение записей с отсутствующими или некорректными значениями;
- **нормализация** – приведение числовых значений к определенному диапазону, например к диапазону 0...1;
- **кодирование** – это представление категориальных данных в числовой форме. Например, при бинарной классификации один из классов можно представить числом «0», а другой класс – числом «1». При множественной классификации система кодирования несколько усложняется: создается несколько числовых полей по количеству классов в выборке данных, каждый класс кодируется проставлением числа «1» в соответствующем поле.

Пример подготовки данных. Пусть имеется выборка анкетных данных клиентов банка (табл. 2).

Таблица 2. Анкетные данные клиентов банка

№	Age	Marital	Balance	Housing
1	47	married	1506	yes
2	33	single	1	no
3	35	married	high	yes
4	28	single	447	yes
5	42	divorced	2	yes
6	58		121	yes
7	43	single	593	yes

Для приведения этой выборки данных в «правильный» формат необходимо выполнить следующие операции:

1) Исключить записи №3 и №6 как имеющие отсутствующие или некорректные значения.
2) Нормализовать числовые значения в столбцах *Age* и *Balance*.
3) Закодировать категориальные данные в столбцах *Marital* и *Housing*.

После выполнения этих операций набор данных примет следующий вид (табл. 3).

Таблица 3. Обработанная выборка данных

№	Age	Marital1	Marital2	Marital3	Balance	Housing
1	1,000	1	0	0	1,000	1
2	0,263	0	1	0	0,000	0
4	0,000	0	1	0	0,296	1
5	0,737	0	0	1	0,001	1
7	0,789	0	1	0	0,393	1

Программное обеспечение

В основе систем анализа данных лежит программное обеспечение. При проектировании систем анализа данных могут быть использованы следующие подходы:

- использование «коробочного» программного обеспечения общего назначения (например Microsoft Excel);
- использование программного обеспечения, ориентированного на математические задачи (например Matlab, Octave, R);
- разработка специализированного программного обеспечения с использованием готовых библиотек, включающих наборы специальных функций обработки данных.

При разработке специализированного ПО рекомендуется использовать готовые библиотеки функций обработки данных. Так, для нейросетевого анализа можно применить библиотеку FANN, имеющую версии для языков программирования C#, C++, Java, Python, R, Matlab, а для решения задач обработки изображений – библиотеку OpenCV, имеющую версии для языков Python, Java, Ruby, Matlab и др.

Общий алгоритм построения системы анализа данных:

1) Постановка задачи.
2) Определение источников данных.
3) Выбор метода и алгоритма обработки данных.
4) Выбор аппаратной платформы.
5) Выбор или разработка программного обеспечения.
6) Верификация построенной системы.

Шаги 3 - 5 тесно связаны друг с другом: например, изменение аппаратной платформы может повлечь необходимость повторной разработки программного обеспечения.

Задание 1: Автоматизированный сбор данных табло аэропортов с применением MS Excel

Вариант	Адрес в сети Интернет
1	https://rov.aero/board/
2	https://www.aer.aero/
3	https://pulkovo-airport.com/passengers/departure/
4	https://www.aeroport-perm.ru/onlajn-tablo/
5	https://www.airport-omsk.ru/onlajn-tablo/
6	https://aeroport-kirov.ru/onlajn-tablo/
7	https://tolmachevo.ru/passengers/information/timetable/
8	https://www.aeroport-izhevsk.ru/onlajn-tablo/
9	https://www.aeroport-orenburg.ru/onlajn-tablo/
10	https://www.aeroport-stavropol.ru/onlajn-tablo/

Задание 2: Исследование наборов данных, представленных на портале открытых данных data.gov.ru

Порядок выполнения:

1. Выберите вариант задания.
2. Найдите произвольный набор данных на портале data.gov.ru по тематике, указанной в выбранном варианте задания. Набор должен быть представлен в формате csv и кодировке Windows.
3. Загрузите на компьютер найденный набор данных и его паспорт.
4. Проведите анализ набора данных: определите количество записей и полей в наборе данных.

Вариант	Тематика	Адрес в сети Интернет
1.	Государство	http://data.gov.ru/rubriki/gosudarstvo
2.	Экономика	http://data.gov.ru/rubriki/ekonomika
3.	Образование	http://data.gov.ru/rubriki/education
4.	Здоровье	http://data.gov.ru/rubriki/zdorove
5.	Экология	http://data.gov.ru/rubrics/ecology
6.	Транспорт	http://data.gov.ru/rubriki/transport
7.	Культура	http://data.gov.ru/rubrics/culture
8.	Спорт	http://data.gov.ru/rubrics/sport
9.	Строительство	http://data.gov.ru/rubriki/stroitelstvo
10.	Торговля	http://data.gov.ru/rubriki/torgovlya
11.	Туризм	http://data.gov.ru/rubrics/tourism
12.	Электроника	http://data.gov.ru/rubrics/electronics
13.	Картография	http://data.gov.ru/rubrics/cartography
14.	Безопасность	http://data.gov.ru/rubriki/bezopasnost
15.	Метеоданные	http://data.gov.ru/rubrics/weather

Задание 3: Исследование наборов данных, представленных на портале data.worldbank.org

Порядок выполнения:

1. Выберите вариант задания.
2. Найдите произвольный набор данных на портале data.worldbank.org по тематике, указанной в выбранном варианте задания.
3. Загрузите на компьютер найденный набор данных в формате XLS.
4. На основе набора данных подготовьте выборку, содержащую значения показателя за все годы для трёх произвольно выбранных стран мира.
5. На основе подготовленной выборки постройте график, иллюстрирующий изменение показателя со временем для трёх стран мира.
6. Сохраните файл.

Вариант	Тематика
1	Agriculture & Rural Development
2	Aid Effectiveness
3	Climate Change
4	Economy & Growth
5	Education
6	Energy & Mining
7	Environment
8	External Debt
9	Financial Sector
10	Gender
11	Health
12	Infrastructure
13	Poverty
14	Private Sector
15	Public Sector
16	Science & Technology
17	Social Development
18	Social Protection & Labor
19	Trade
20	Urban Development